

## 2.1 Эксперимент: Зависимость числа итераций метода сопряженных градиентов от числа обусловленности и размерности пространства

Задача:

исследовать, как зависит число итераций от числа обусловленности  $k \geq 1$  оптимизируемой функции и размерности пространства  $n$  оптимизируемых переменных. Сравнить результат метода сопряженных градиентов с результатом градиентного спуска



Рисунок 1. Зависимость числа итераций от размерности пространства  $n$  и числа обусловленности  $k$ . Метод сопряженных квадратов

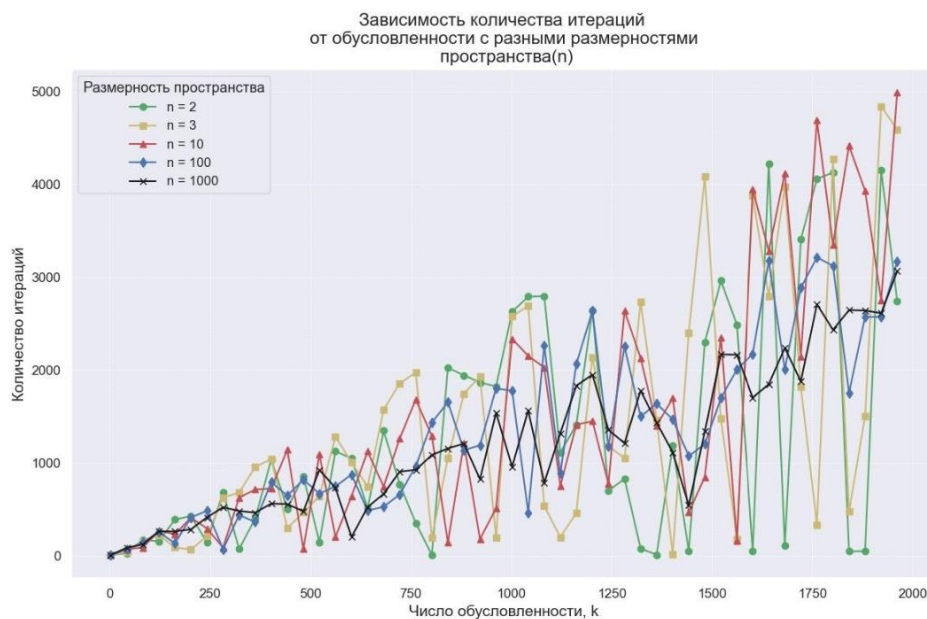


Рисунок 2. Зависимость числа итераций от размерности пространства  $n$  и числа обусловленности  $k$ . Градиентный спуск

Вывод:

Для низкоразмерных пространств  $n = 2, 3, 10$  метод сопряженных градиентов показывает стабильность и эффективность, что выражается в минимальном изменении количества итераций при изменении числа обусловленности. Для высоких размерностей вроде  $n = 1000$  количество итераций значительно возрастает из-за вычислительной сложности. Сама производительность варьируется в зависимости от числа обусловленности( $k$ ), так как обычно больше  $k$  – больше итераций, особенно в высокоразмерных пространствах. Метод сопряженных градиентов лучше как при маленькой размерности  $n = 2, 3, 10$ , так и при большой  $n = 100, 1000$ . Он требует меньше итераций для сходимости по сравнению с градиентным спуском независимо от размерности пространства

## 2.2 Эксперимент: Выбор размера истории в методе L-BFGS.

Задача:

исследовать как влияет размер истории в методе L-BFGS на поведение метода.  
Выбрано несколько вариантов размера истории [1, 5, 10, 20, 50, 100]

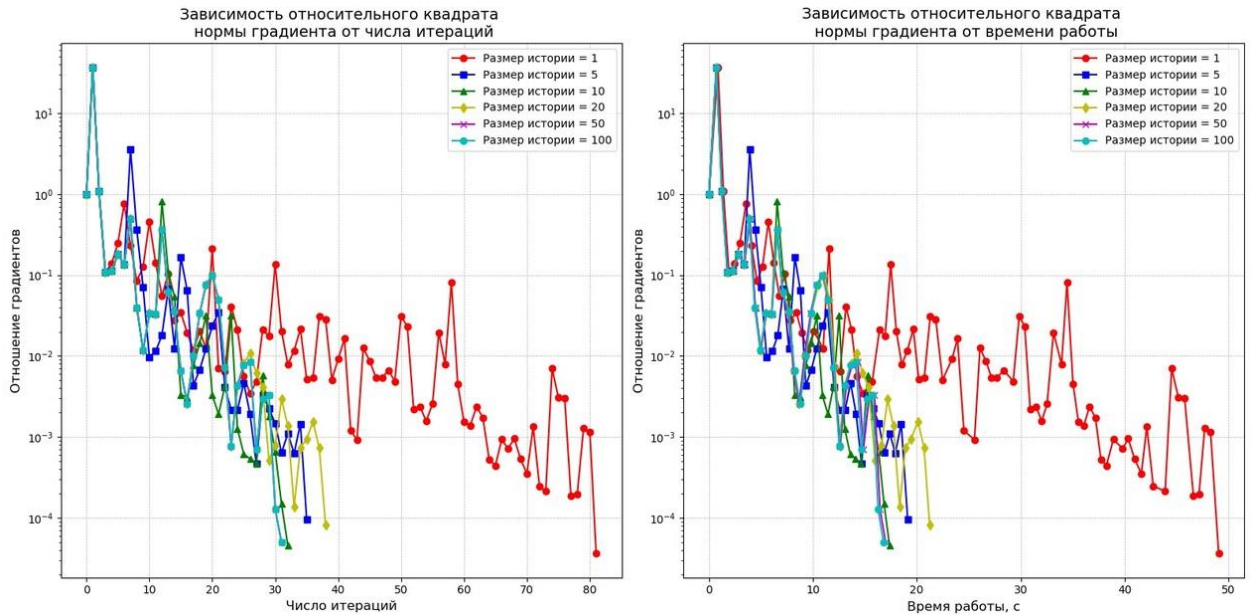


Рисунок 3. Зависимости в полулогарифмическом масштабе относительной нормы градиентов от времени работы и числа итераций. Датасет gisette




Рисунок 4. Зависимости в полулогарифмическом масштабе относительной нормы градиентов от времени работы и числа итераций. Датасет news20

Вывод:

Во-первых, чем больше история - тем быстрее работает алгоритм: это видно из графиков, где увеличение размера истории позволяет быстрее снижать норму градиента как по числу итераций, так и по времени работы. Также большая история приводит к меньшему числу резких скачков. Это делает алгоритм более предсказуемым и стабильным. Увеличение размера истории позволяет достигать сходимости за меньшее количество итераций. Это видно из того, что при большом размере истории норма градиента снижается быстрее и более плавно

## 2.3 Эксперимент: Сравнение методов на реальной задаче логистической регрессии

Задача:

Сравнить усеченный метод Ньютона, метод L-BFGS и градиентный спуск на реальной задаче логистической регрессии. Сравнить методы между собой

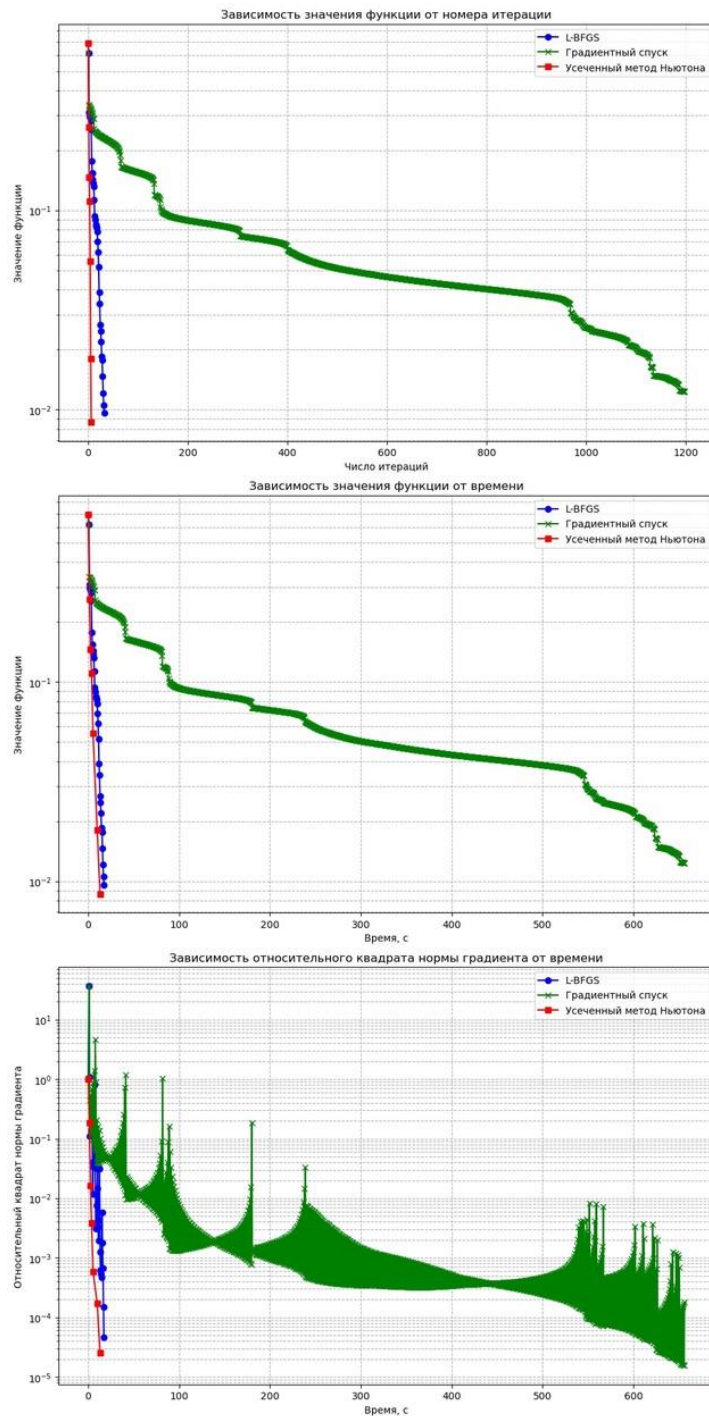


Рисунок 5. Зависимости в логарифмическом масштабе по одной оси н.град. по времени и числу итераций. gisete

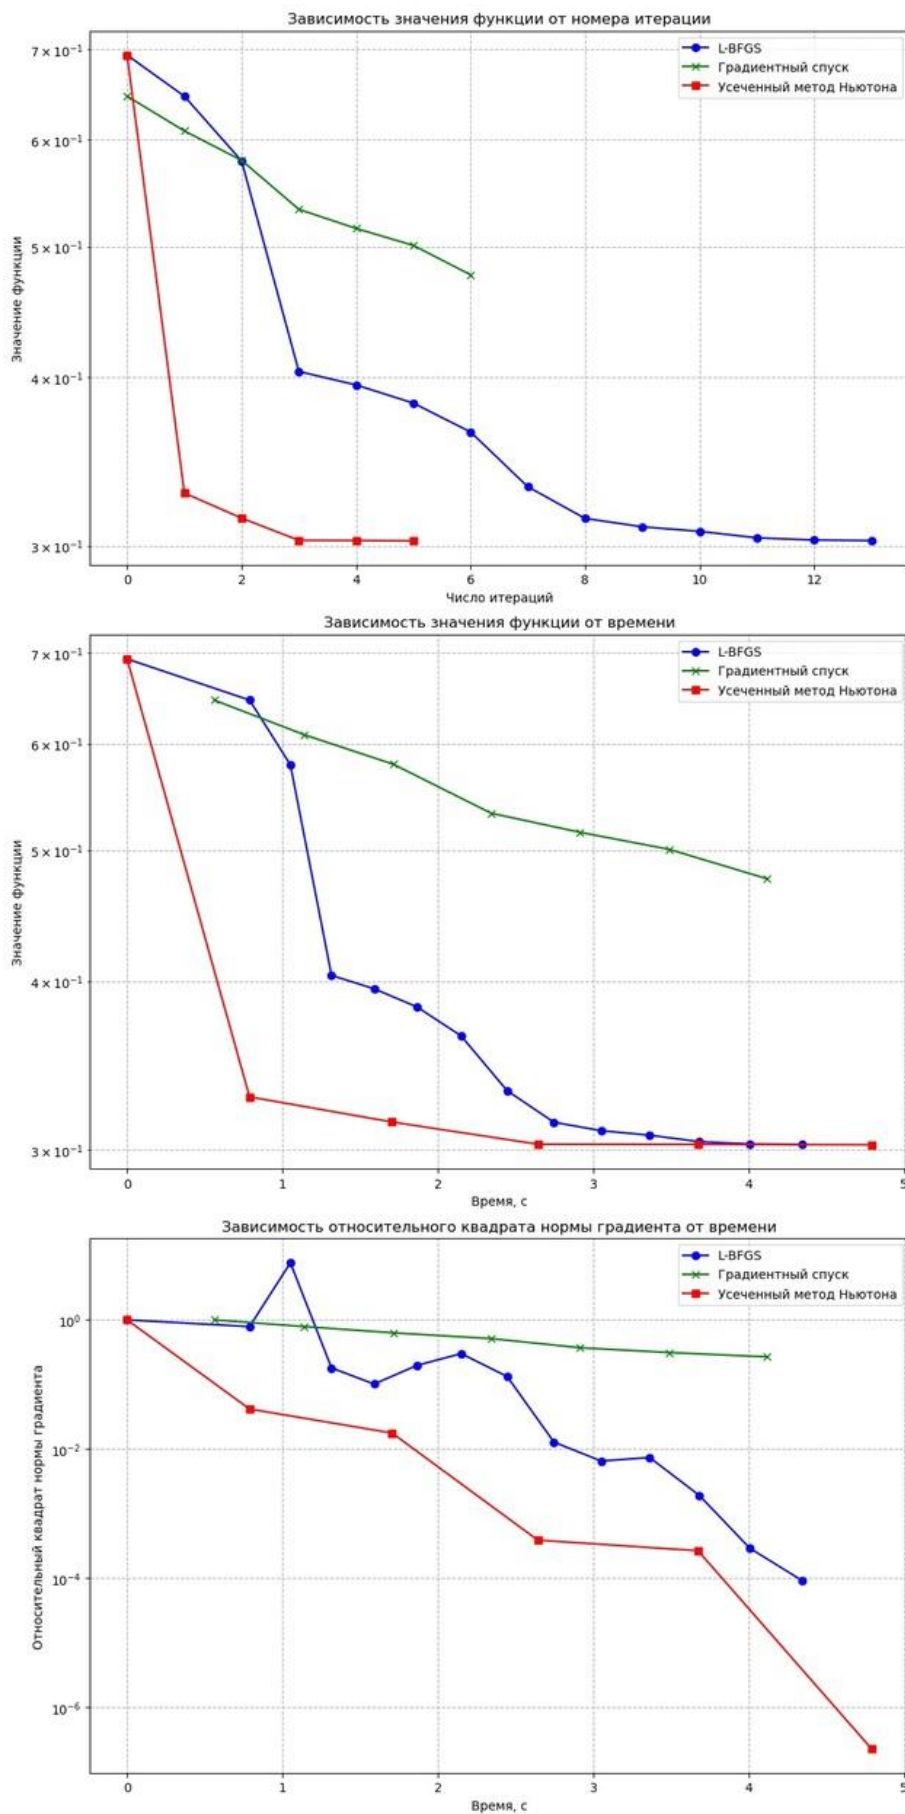


Рисунок 6. Зависимости в логарифмическом масштабе по одной оси н.град. по времени и числу итераций. News20



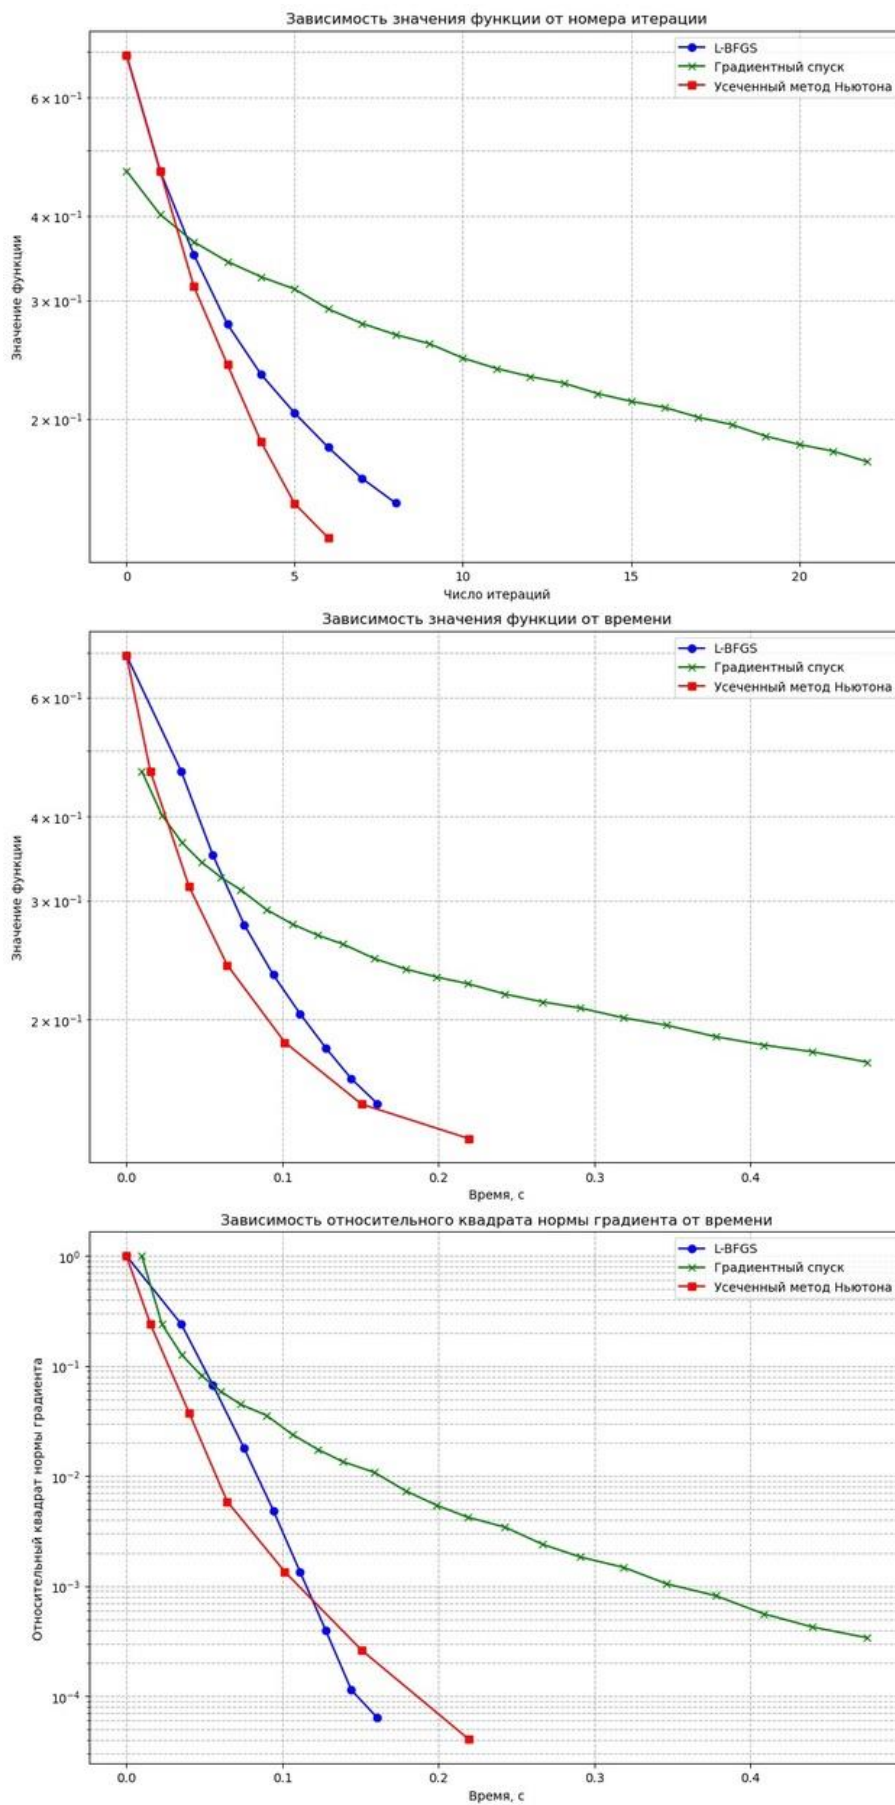


Рисунок 7. Зависимости в логарифмическом масштабе по одной оси н.град. по времени и числу итераций.w8a




Рисунок 8. Зависимости в логарифмическом масштабе по одной оси н.град. по времени и числу итераций. realsim



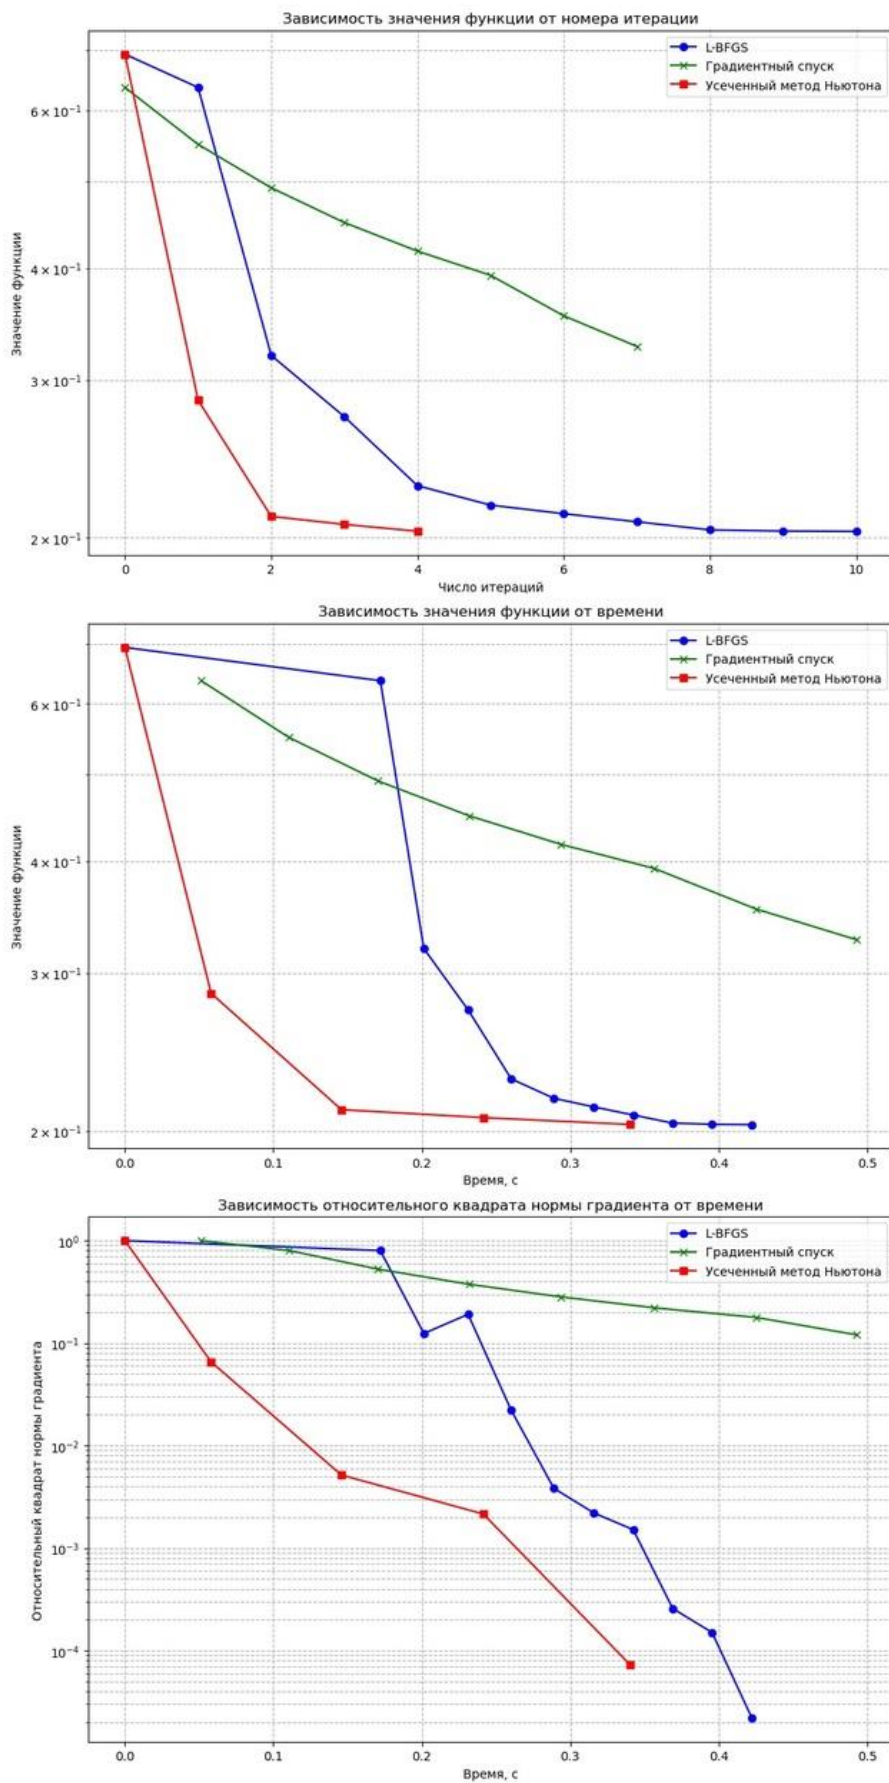


Рисунок 9. Зависимости в логарифмическом масштабе по одной оси н.град. по времени и числу итераций.csv

#### Вывод:

На датасете gisette усеченный метод Ньютона (красный) сходится за минимальное количество итераций (менее 5). Метод L-BFGS (синий) требует около 10, а градиентный спуск (зелёный) требует в разы больше итераций. Схожая картина наблюдается и на других 4 датасетах. Можно заключить, что усеченный метод Ньютона является лучшим выбором, так как он показывает наилучшую скорость и стабильность сходимости. Метод L BFGS является тоже хорошим вариантом, который работает лучше, чем градиентный спуск, но уступает усеченному методу Ньютона